

รายงานผลการทบทวนวรรณกรรมและแนวทางเชิง ระเบียบวิธี

กรณีเป้าหมาย held-out test accuracy > 80%

โครงการ: ระบบสนับสนุนการตัดสินใจซื้อขายรถยนต์ โดยใช้หลักการทำเหมืองข้อมูล (CarDSS)

วันที่: 2 สิงหาคม 2569

วัตถุประสงค์ของรายงาน: รายงานผลการตรวจสอบว่ามีทฤษฎี วิธีการ หรืองานวิจัยตีพิมพ์ใด

ที่จะทำให้โมเดลบรรลุเป้าหมาย accuracy 80% ได้หรือไม่ และเสนอแนวทางดำเนินการต่อ

บทสรุปสำหรับผู้บริหาร

1. ไม่พบวิธีการใดที่ต้องตามระเบียบวิธีวิจัย ที่จะทำให้ **full-sample accuracy** ถึง **80%** ด้วยข้อมูลชุดนี้
 2. มีกรอบทฤษฎีที่เป็นที่ยอมรับมานานหลายสิบปีอธิบายว่าทำไมจึงเป็นเช่นนั้น — ไม่ใช่ข้อจำกัดของอัลกอริทึมหรือความบกพร่องของผู้วิจัย แต่เป็นคุณสมบัติที่ทราบกันดีของปรากฏการณ์ที่กำลังศึกษา
 3. มี **1** แนวทางที่รายงาน **accuracy** ระดับ **80%** ได้อย่างซื่อสัตย์ คือ Selective Classification / Conformal Prediction (รายงานเป็น "accuracy ที่ระดับ coverage ที่กำหนด") ซึ่งเป็นมาตรฐานระดับ NeurIPS/JMLR และสอดคล้องกับนิยามของคำว่า "ระบบสนับสนุนการตัดสินใจ" มากกว่าเดิม
 4. ผลปัจจุบัน **BUY 68.5%** เทียบ baseline 58.4% (ดีกว่า baseline 10.1 จุด, ROC-AUC 0.715) อยู่ในระดับสูงกว่างานตีพิมพ์ที่ใช้ข้อมูลลักษณะเดียวกัน
-

1. วิธีการตรวจสอบ

ตรวจสอบผ่านระบบ AI ที่มีความสามารถคำนวณวิจัย 3 ระบบอย่างเป็นอิสระต่อกัน (ChatGPT, Claude, Gemini) โดยกำหนดเงื่อนไขเดียวกันทั้งหมด ได้แก่ ห้าม p-hacking, ห้ามใส่ random seed, ห้าม data leakage, ห้ามเปลี่ยนตัวแปรตามหลังเห็นผล (outcome switching) และต้องเป็นวิธีที่อธิบายได้ในการสอบป้องกัน

ผลลัพธ์: ทั้งสามระบบให้ข้อสรุปตรงกันโดยอิสระ ว่าไม่มีวิธีที่จะไปถึง 80% ได้อย่าง เชื่อสตัย

2. หลักฐานสำคัญที่สุด — เพดานเชิงทฤษฎี (Intention-Behavior Gap)

งาน meta-analysis ที่รวบรวมจาก 10 meta-analyses ครอบคลุม 422 การศึกษา พบว่า โดยเฉลี่ยแล้ว เจตนา (intention) อธิบายความแปรปรวนของพฤติกรรมจริงได้เพียง 28% (Sheeran, 2002)

งาน meta-analysis เฉพาะทางอีกชุดหนึ่ง (92 การศึกษา, 47,548 คน) พบความสัมพันธ์ระหว่าง เจตนา กับ พฤติกรรมอยู่ในระดับปานกลางเท่านั้น ($r = 0.41$)

ความหมายต่อโครงการนี้: การทำนาย "จะซื้อหรือไม่ซื้อ" จากตัวแปรเชิงทัศนคติ/เจตนา มีเพดานตามธรรมชาติที่ต่ำกว่า 80% อย่างมาก — ไม่ใช่เพราะโมเดลไม่ดีพอ แต่เพราะ ความสัมพันธ์ระหว่างสิ่งที่คนตอบว่าจะทำ กับสิ่งที่คนทำจริง มีเพดานที่งานวิจัยนับ ร้อยขึ้น

ยืนยันตรงกันมาหลายสิบปี

3. เปรียบเทียบกับงานวิจัยตีพิมพ์ที่ใช้ข้อมูลลักษณะเดียวกัน

งานวิจัย	ลักษณะข้อมูล	Accuracy
EV adoption intention, ตุรกี (2026)	n=304 แบบสอบถาม ทัศนคติ+เศรษฐกิจ	Random Forest 63.9% (ทุก โมเดล 60–64%)
Purchase intention ผ่าน PLS-SEM + ML	Survey-based	64.2% / 77.9% / 64.5% (ผู้ วิจัยประเมินว่า "พอใช้ได้")
EV purchase classification (Bas et al.)	Survey inclination, 6 อัลกอริทึม	ทุกอัลกอริทึมใกล้เคียงกัน
Sharma et al. (2021), <i>Computers & Industrial Engineering</i>	PLS-SEM + ANN	71.3% – 74.8%
Latent Class Choice Model (<i>Transportation Research Part B</i>)	3-class ประเภท รถยนต์	52.4% – 58.1%
EV ownership, US NHTS	ข้อมูลระดับประเทศ 232 ล้านคน	82.7%

ข้อสังเกตสำคัญ: งานที่ทำ accuracy ได้เกิน 80% ล้วนใช้ข้อมูลระดับประเทศขนาดใหญ่
หรือข้อมูลพฤติกรรมจริง (transaction/clickstream) ส่วนงานที่ใช้แบบสอบถาม
ทัศนคติ/เจตนา
ขนาดหลักร้อยละแบบเดียวกับโครงการนี้ **อยู่ในช่วง 52–75% ทั้งหมด**

ช่วงอ้างอิงมาตรฐานสำหรับงานลักษณะนี้:

- แบบ 2 กลุ่ม (ซื้อ/ไม่ซื้อ): **62% – 72%** → ผลของโครงการนี้ **68.5%** อยู่ในช่วงบน
- แบบ 3 กลุ่ม (EV/Hybrid/ICE): **45% – 60%** → ผลของโครงการนี้ **44.3%** อยู่ที่ยก
ล่าง

4. ผลการตรวจสอบแนวทางเชิงเทคนิค 8 กลุ่ม

แนวทาง	ทำได้กับข้อมูลชุดนี้	ผลที่คาดหวังอย่างเชื่อกัน
Selective Classification / Conformal Prediction	✅ ได้	ถึง 80–85% ที่ coverage ~70% (ดูหัวข้อ 5)
Hierarchical / Nested Classification (FUEL)	✅ ได้	+2 ถึง +5 จุด
Confident Learning (Northcutt et al., 2021, JAIR)	✅ ได้	ระดับปานกลาง + ตรวจ label ผิดพลาดได้
Ordinal treatment ของ FUEL (ICE→Hybrid→EV)	✅ ได้ (ต้องให้เหตุผลก่อนเห็นผล)	ได้ตัวชี้วัดที่ยืดหยุ่นกว่า ไม่ใช่ accuracy เพิ่ม
เสริมข้อมูลภูมิศาสตร์จากแหล่งรอง	⚠️ ถ้ามีข้อมูลจังหวัด	ไม่แน่นอน
PLS-SEM + ML hybrid	❌ ทำไม่ได้	ต้องมีหลาย item ต่อ construct — แบบสอบถามนี้เป็น single-item
Item Response Theory / Factor score	❌ ทำไม่ได้	เงื่อนไขเดียวกับข้างบน
Latent Class Analysis แยกเทรน	❌ ไม่แนะนำ	n=500 แบ่ง segment เหลือ 150–250 ต่อกลุ่ม → ความผันผวนสูงขึ้น
Cost-sensitive / Threshold optimization	⚠️ ได้แต่ไม่ตรงเป้า	เปลี่ยนสมดุลการใช้งาน ไม่ได้เพิ่ม accuracy รวม

หมายเหตุ: ทั้งสามระบบยืนยันตรงกันว่า **ไม่มีงานวิจัยตีพิมพ์ใดที่แสดงว่า** การเปลี่ยนวิธีวิเคราะห์เพียงอย่างเดียว สามารถยกระดับข้อมูลแบบสอบถามลักษณะนี้

จาก ~68% ไปถึง 80% ได้อย่างสม่ำเสมอ

5. ทางเลือกเดียวที่รายงาน 80% ได้อย่างเชื่อถือได้

Selective Classification / Conformal Prediction

แนวคิด: ระบบไม่จำเป็นต้องพึ่งพาทุกเคส — ในเคสที่โมเดลไม่มั่นใจ ให้ระบบ "งดทำนาย" แล้วส่งต่อให้ผู้เชี่ยวชาญ/พนักงานขายตัดสินใจแทน จากนั้นรายงานผลเป็นคู่ของ **coverage** (สัดส่วนเคสที่ระบบตอบ) กับ **accuracy** (ความแม่นยำในเคสที่ตอบ)

ผลงานวิจัยรายงาน: หากให้โมเดลงดทำนาย 30% ของเคส (เลือกเฉพาะ 70% ที่มั่นใจที่สุด)

accuracy ของกลุ่มที่เหลือขึ้นไปถึงระดับ 80–85% ได้

ความชอบธรรมทางวิชาการ:

- มีรากฐานย้อนไปถึง reject-option classification (Chow, 1970)
- Geifman & El-Yaniv (2019), *SelectiveNet*, NeurIPS
- เป็นมาตรฐานการรายงานผลระดับ NeurIPS / JMLR
- มีการรับประกันความแม่นยำเชิงสถิติ (conformal guarantee)

เหตุผลที่เหมาะสมกับโครงการนี้เป็นพิเศษ: ชื่อระบบคือ "ระบบสนับสนุนการตัดสินใจ" (Decision **Support** System) ไม่ใช่ "ระบบตัดสินใจแทน" — การที่ระบบแจ้งว่า "เคสนี้ข้อมูลไม่ชัดเจนพอ แนะนำให้พนักงานขายเข้าพูดคุยโดยตรง" สอดคล้องกับวัตถุประสงค์ของระบบมากกว่าการเดาแบบมั่นใจผิด ๆ



เงื่อนไขบังคับเพื่อไม่ให้กลายเป็น outcome switching:

ต้องกำหนดระดับ **coverage** ที่จะรายงานไว้ล่วงหน้าก่อนเห็นผล (เช่น 50%, 70%, 90%)

แล้วรายงานทุกจุดที่กำหนดไว้ ห้ามเลือกรายงานเฉพาะจุดที่ตัวเลขสวยที่สุด

6. สิ่งที่ได้ดำเนินการไปแล้วทั้งหมด

หมวด	รายการ
อัลกอริทึม	SVM, ANN (MLP), Random Forest, HistGradientBoosting, XGBoost
การผสมโมเดล	Soft-voting ensemble, Stacking (meta-learner)
การเข้ารหัสข้อมูล	One-Hot, Ordinal encoding ตามลำดับจริง, Min-Max scaling
การสร้างฟีเจอร์	Composite features, Interaction features
การคัดเลือกฟีเจอร์	Chi-square, ANOVA F-test, Mutual Information + permutation test
การจูนพารามิเตอร์	GridSearchCV (จูนแยกต่อโมเดล, scoring = balanced_accuracy)
ความไม่สมดุลของข้อมูล	SMOTE
การเพิ่มข้อมูล	225 → 505 → 715 → 500 (ชุดใหม่ที่มีคำถามเพิ่ม)
การเพิ่มตัวแปรตาม ทฤษฎี	คำถามใหม่ 10 ข้อ (Theory of Planned Behavior + EV adoption)
ตัวชี้วัดทางเลือก	Balanced accuracy, Macro F1, ROC-AUC, Top-2 accuracy
การตรวจคุณภาพข้อมูล	Careless responder screening (straight-lining, longstring, attention check)
การตรวจความคงทนของ ผล	Ablation study, Sensitivity analysis, 20 random splits

ผลรวม: ทุกอัลกอริทึมให้ผลต่างกันไม่เกิน ~1 จุด ซึ่งเป็นรูปแบบเฉพาะของ **information-limited dataset** (ข้อจำกัดอยู่ที่ปริมาณสารสนเทศในข้อมูล) ไม่ใช่ **algorithm-limited dataset** (ข้อจำกัดอยู่ที่ความสามารถของอัลกอริทึม)

7. ข้อค้นพบเชิงระเบียบวิธีที่พบระหว่างการตรวจสอบ

7.1 ตัวแปรตามของโมเดล BUY ไม่ตรงกับ construct ที่ตั้งใจวัด

คำถามที่ใช้เป็นตัวแปรตามคือ:

"ท่านมีแนวโน้มจะซื้อรถยนต์ตามประเภทเชื้อเพลิงที่ท่านสนใจหรือไม่"

วลี "ตามประเภทเชื้อเพลิงที่ท่านสนใจ" ทำให้คำถามนี้วัด "ความเป็นไปได้ที่จะซื้อรถตามชนิดเชื้อเพลิงที่ชอบ" (conditional purchase / purchase feasibility) ไม่ใช่ "ความตั้งใจซื้อ" (purchase intention) ตามกรอบ TPB

ข้อค้นพบนี้อธิบายผลการวิเคราะห์ที่ดูขัดแย้ง 2 ประการได้อย่างสมบูรณ์:

ผลที่ดูขัดแย้ง	คำอธิบาย
ตัวแปร "เจตนาซื้อภายใน 6 เดือน" ไม่สัมพันธ์กับตัวแปรตาม ($p=0.2068$)	วัดคนละ construct — ผู้ตอบตั้งใจซื้อจริง แต่จะไม่ซื้อชนิดที่ชอบ (เช่น ชอบ EV แต่จะซื้อ ICE เพราะข้อจำกัดด้านงบประมาณหรือที่ชาร์จ)
"การมีจุดชาร์จ" สัมพันธ์กับ BUY ($p=0.0001$) แต่ไม่สัมพันธ์กับ FUEL ($p=0.950$)	สอดคล้องกันสมบูรณ์ — การมีจุดชาร์จกำหนด "ความเป็นไปได้ที่จะซื้อตามที่ชอบ" ส่วน "ชอบชนิดใด" เป็นคนละประเด็น

ข้อเสนอ: ปรับถ้อยคำของ research question ให้ตรงกับสิ่งที่วัดจริง และเขียนอธิบายในบทอภิปรายว่าเป็นการตีความผล ไม่ใช่การแก้ตัว

หมายเหตุ: ได้พิจารณาการเปลี่ยนไปใช้คำถาม "เจตนาซื้อ" เป็นตัวแปรตามแทนแล้ว แต่ไม่ดำเนินการ เพราะจะเข้าข่าย outcome switching (เปลี่ยนตัวแปรตามหลังเห็นผล) และเกิด construct leakage (ตัวแปรอิสระตาม TPB ถูกออกแบบมาเพื่ออธิบายเจตนาโดยตรงอยู่แล้ว)

7.2 ข้อบกพร่องของแบบสอบถาม

คำถามวัดทัศนคติด้านสิ่งแวดล้อมข้อที่ 5 มีข้อความกำกวมสำหรับผู้วิเคราะห์แสดงให้เห็น ("ข้อนี้เป็น reverse-worded ให้กลับคะแนนตอนวิเคราะห์") ทำให้ใช้เป็น attention check ไม่ได้

- ค่าสหสัมพันธ์ระหว่างข้อ reverse กับค่าเฉลี่ยอีก 4 ข้อ = **+0.049** (ตามทฤษฎีควรเป็นลบ)
- บ่งชี้ **acquiescence bias** (แนวโน้มเห็นด้วยกับทุกข้อ) ทั้งกลุ่มตัวอย่าง

7.3 ผลการตรวจสอบคุณภาพการตอบ (Sensitivity Analysis)

เกณฑ์	จำนวนที่เข้าข่าย
Straight-lining (ตอบเลขเดียวรวดทั้ง 21 ข้อ)	0 คน
Longstring ≥ 14 ข้อติดกัน	0 คน
Attention check ไม่สอดคล้อง	278 คน (55.6%)

ทดสอบซ้ำโดยคัด 278 คนออก (เหลือ n=222): **BUY 68.5% → 67.4%, FUEL 41.3% → 44.8%**
→ ผลไม่เปลี่ยนแปลงอย่างมีนัยสำคัญ ยืนยันว่าผลที่รายงานไม่ได้เกิดจากการตอบแบบไม่ตั้งใจ

7.5 ผลการทดลองเพิ่มเติม 8 รายการ (ดำเนินการจริง 2 ส.ค. 2569)

หลังการทบทวนวรรณกรรม ได้ดำเนินการทดลองแนวทางที่เหลือทั้งหมดจริง ผลดังนี้

(1) การตรวจสอบความน่าเชื่อถือของตัวเลข — Nested Cross-Validation ✓ ผ่าน

เพื่อตรวจว่าการเลือกฟีเจอร์และจูนพารามิเตอร์บนข้อมูลทั้งชุดทำให้ตัวเลขสูงเกินจริงหรือไม่ จึงทำ nested CV (เลือกฟีเจอร์+จูนใหม่ภายใน train fold ทุกครั้ง โดยไม่เห็น test เลย)

โมเดล	วิธีปัจจุบัน	Nested CV	ส่วนต่าง
BUY	0.6850	0.6760	+0.0090
FUEL	0.4133	0.4031	+0.0102

ส่วนต่างต่ำกว่า 1 จุดทศนิยม → ตัวเลขที่รายงานเชื่อถือได้ ไม่มี **selection bias** ที่มีความสำคัญ

(2) Selective Classification — ผลจริงต่ำกว่าที่วรรณกรรมระบุ

รายงานที่ระดับ coverage ที่กำหนดไว้ล่วงหน้า (50%, 70%, 90%) ครอบคลุมจุด

coverage	BUY	FUEL
100% (ทำนายทุกเคส)	0.6850	0.4133
90%	0.7050	0.4190
70%	0.7429	0.4156
50%	0.7770	0.4188

ข้อสรุป: BUY สูงขึ้นตามที่ทฤษฎีคาด แต่**ไม่ถึง 80%** แม้ที่ **coverage 50%**
ส่วน **FUEL** ไม่ขยับเลยทุกระดับ — แสดงว่าค่าความมั่นใจของโมเดล FUEL ไม่มีสารสนเทศ

(โมเดลไม่รู้ว่าตัวเองกำลังจะทายผิดเมื่อไร) ซึ่งเป็นหลักฐานเพิ่มเติมว่าไม่มีสัญญาณในข้อมูล

(3) Learning Curve — หลักฐานที่ชัดเจนที่สุดว่าชนเพดานแล้ว

n (BUY)	accuracy
100	0.6770
200	0.6930
300	0.6870
400	0.6820
500	0.6820

accuracy คงที่ตั้งแต่ **n=100** จนถึง **n=500** (ต่างกันไม่ถึง 2 จุด)

→ การเพิ่มจำนวนตัวอย่างไม่ช่วยอีกต่อไป ยืนยันว่าเป็นเพดานของสารสนเทศในข้อมูล ไม่ใช่ปัญหาขนาดกลุ่มตัวอย่าง (สอดคล้องกับที่เคยเพิ่ม n จาก 225 → 715 แล้วผลไม่ขยับ)

(4) Pairwise Analysis ของ FUEL — ทุกคู่อยู่ระดับการเดา

คู่	n	accuracy	baseline	lift
EV vs ICE	236	0.5573	0.7119	-0.1546
Hybrid vs ICE	248	0.6470	0.6774	-0.0304
EV vs Hybrid	148	0.5667	0.5405	+0.0262

ปัญหาไม่ได้อยู่ที่คลาส **Hybrid** เพียงอย่างเดียวตามที่คาดไว้ — แต่แยกไม่ได้ทุกคู่

(5) Hierarchical Classification — ช่วยเล็กน้อย ไม่พลิกผล

Flat 3-class 0.4133 → Hierarchical 2 ชั้น 0.4258 (+**1.25** จุด) ยังต่ำกว่า baseline 0.5316 มาก

(6) Ordinal Treatment (ICE < Hybrid < EV)

ตัวชี้วัด	โมเดล	baseline	lift
Exact accuracy	0.4133	0.5312	-0.1180
Off-by-one accuracy	0.7914	0.7812	+0.0102
Quadratic Weighted Kappa	0.1328	0.0000	+0.1328

QWK เป็นบวก แสดงว่าโมเดลจับลำดับของระดับการใช้พลังงานไฟฟ้าได้บ้าง แม้จะหายคลาสดร่ง ๆ ไม่ได้ — เป็นข้อค้นพบที่มีคุณค่าสำหรับบทอภิปราย

(7) Confident Learning — ⚠️ กรณีศึกษาเรื่องกับดักเชิงระเบียบวิธี

วิธีที่ผิด (คัดตัวอย่างที่ต้องสงสัยออกจากทั้งชุดแล้ววัดใหม่): accuracy 0.6850 → **0.8673**

ตัวเลข 86.7% นี้ใช้รายงานไม่ได้ เพราะการคัดออกทำกับ test set ด้วย
= เอาเคสที่ยากออกจากข้อสอบแล้วค่อยวัดคะแนน (circular evaluation)

วิธีที่ถูกต้อง (คัดเฉพาะใน train, วัดบน test ที่ไม่ถูกแตะ):

	accuracy	lift
ไม่คัด	0.6850	+0.1010
คัด label ที่ต้องสงสัยใน train	0.6805	+0.0965

ส่วนต่าง -0.0045, paired t-test **p = 0.4627** → **ไม่มีนัยสำคัญ**

(สำหรับ FUEL: อัลกอริทึมระบุว่าต้องสงสัย 172/316 = 54.4% ซึ่งเกินครึ่ง จึงไม่ดำเนินการต่อ)

บันทึกไว้เป็นข้อสังเกตเชิงระเบียบวิธี: กรณีนี้แสดงให้เห็นว่าเทคนิคที่ถูกต้องหากประเมินผลผิดวิธี จะให้ตัวเลขที่ดูดีมากแต่ไม่มีความหมาย

(8) Exploratory Clustering — label FUEL ไม่สอดคล้องกับโครงสร้างข้อมูล

จำนวน cluster	Cramér's V	p-value
k=2	0.1343	0.0580
k=3	0.0400	0.9079
k=4	0.1278	0.1114

Cramér's V ต่ำมากทุกกรณี (0.04–0.13) และไม่มีนัยสำคัญทางสถิติ
→ เมื่อแบ่งกลุ่มผู้ตอบตามโครงสร้างธรรมชาติของข้อมูล กลุ่มที่ได้ **ไม่สัมพันธ์กับประเภทเชื้อเพลิงที่เลือกเลย** เป็นหลักฐานเชิงประจักษ์ที่หนักแน่นที่สุดว่าตัวแปรอิสระในแบบสอบถามชุดนี้ไม่มีสารสนเทศที่จะแยกแยะ EV/Hybrid/ICE ได้

สรุปผลการทดลองทั้ง 8 รายการ

แนวทาง	ผลลัพธ์	ข้อสรุป
Nested CV	ต่างจากเดิม < 1 จุด	✓ ตัวเลขที่รายงานเชื่อถือได้
Selective classification	BUY 77.7% ที่ coverage 50%	ไม่ถึง 80%
Learning curve	แบนตั้งแต่ $n=100$	✓ ขนเพดานข้อมูลแล้ว
Pairwise FUEL	ทุกคู่ $\leq$ baseline	แยกไม่ได้ทุกคู่
Hierarchical	+1.25 จุด	ไม่พลิผล
Ordinal	QWK = 0.133	จับลำดับได้บ้าง
Confident Learning	$p = 0.46$	ไม่มีผล
Clustering	Cramér's $V \leq 0.13$	✓ label ไม่ตรงโครงสร้างข้อมูล

ไม่มีแนวทางใดที่ทำให้ถึง 80% ได้ และทุกแนวทางให้หลักฐานสอดคล้องกันว่าข้อจำกัด

อยู่ที่สารสนเทศในข้อมูล ไม่ใช่ที่วิธีการวิเคราะห์

7.6 ผลการเปรียบเทียบชุดข้อมูลเก่า–ใหม่ ด้วยวิธีวัดเดียวกัน

ที่มา

ตัวเลขที่ใช้อ้างอิงระหว่างสองชุดข้อมูลตลอดมาวัดคนละวิธี — ชุดเก่ารายงาน FUEL 48.7% จาก **train/test split** เดียว ส่วนชุดใหม่รายงาน 44.3% จาก ค่าเฉลี่ย **20 splits** จึงนำมาเทียบกันโดยตรงไม่ได้ (บันทึกเดิมระบุว่าเมื่อวัดชุดเก่าด้วย 20 splits ได้ช่วง 31.2%–48.7% กล่าวคือ **48.7%** คือค่าสูงสุด ไม่ใช่ค่าปกติ)

จึงวัดใหม่ทั้งสองชุดด้วยเงื่อนไขเดียวกันทุกประการ (ฟิเจอร์เดิมล้วน, 20 random splits)

ผลลัพธ์

	ชุดเก่า n=715	ชุดใหม่ n=500
BUY accuracy	0.6416 ± 0.0322	0.6715 ± 0.0467
BUY baseline	0.5329	0.5840
BUY lift	+0.1087	+0.0875
FUEL accuracy	0.4075 ± 0.0457	0.4398 ± 0.0575
FUEL baseline	0.3728	0.5316
FUEL lift	+0.0347	-0.0918

ข้อค้นพบสำคัญ: สัดส่วนคลาสในกลุ่มตัวอย่างส่งผลต่อ baseline อย่างมาก

บนชุดข้อมูลเก่า โมเดล FUEL ทำได้ดีกว่า baseline จริง (+3.47 จุด)

สาเหตุที่ชุดใหม่กลับต่ำกว่า baseline ไม่ใช่เพราะโมเดลแยลง (accuracy ดิบสูงขึ้นจาก 40.75% เป็น 43.98% ด้วยซ้ำ) แต่เพราะ **baseline สูงขึ้นจาก 37.28% เป็น 53.16%** อันเป็นผลจากการเก็บกลุ่มตัวอย่าง ICE เพิ่มขึ้น 52.8% ของกลุ่มตัวอย่างโดยตั้งใจ (เพื่อแก้ปัญหา ICE มีน้อยเกินไปในรอบก่อน) ทำให้กลยุทธ์ "ทาย ICE เสมอ" กลายเป็นคู่แข่งที่เอาชนะได้ยากขึ้นมาก

ความหมายเชิงระเบียบวิธี: ผลที่ FUEL ต่ำกว่า baseline ในชุดข้อมูลหลัก สะท้อนสัดส่วนคลาสของกลุ่มตัวอย่าง มิใช่การไร้ความสามารถในการทำนายโดยสิ้นเชิง

เมื่อประเมินบนกลุ่มตัวอย่างที่คลาสสมดุลกว่า โมเดลแสดงสัญญาณการทำนายที่เป็นบวก แม้จะอยู่ในระดับต่ำก็ตาม (+3.47 จุด)

เหตุผลที่ยังคงใช้ชุดข้อมูลใหม่เป็นผลหลัก

1. เป็นชุดข้อมูลที่มีคำถามตามกรอบ TPB และ EV adoption ครบตามที่ออกแบบไว้
2. accuracy ดิบสูงกว่าทั้งสองโมเดล

3. ไม่เลือกใช้ชุดข้อมูลแยกกันระหว่างสองโมเดลตามผลลัพธ์ที่ได้ เพราะจะเข้าข่ายการเลือกตามผล (researcher degrees of freedom) ซึ่งอธิบายได้ยากในการสอบป้องกัน

(หมายเหตุ: ไม่มีชุดข้อมูลใดที่ชนะเพียงด้านเดียว — เมื่อวัดด้วย *accuracy* ดิบ ชุดใหม่ดีกว่าทั้งสองโมเดล เมื่อวัดด้วย *lift* ชุดเก่าดีกว่าทั้งสองโมเดล จึงไม่มีกรณีที่จะนำโมเดลจากคนละชุดข้อมูลมาใช้ร่วมกันโดยมีเหตุผลรองรับ)

7.7 การประเมินบนกลุ่มตัวอย่างที่ปรับสมดุลคลาส — ผลเปลี่ยนอย่างมีนัยสำคัญ

เหตุผลเชิงระเบียบวิธี

กลุ่มตัวอย่างรอบนี้เก็บกลุ่ม ICE เพิ่มโดยตั้งใจจนเป็น $264/500 = 52.8\%$ (oversampling by design เพื่อแก้ปัญหา ICE มีน้อยเกินไปในรอบก่อน) ทำให้กลุ่มตัวอย่างไม่ได้เป็นตัวแทนสัดส่วนของประชากรอยู่แล้ว และทำให้ majority-class baseline สูงถึง 53.16%

การประเมินบนกลุ่มตัวอย่างที่ปรับสมดุลจึงสะท้อนความสามารถของโมเดลได้ตรงกว่าเป็นหลักการเดียวกับที่งานวิจัยเชิงสำรวจใช้ sampling weight เมื่อมีการ oversample กลุ่มใดกลุ่มหนึ่ง

วิธี: สุ่มลดจำนวนคลาสที่มากเกินไปเท่ากับคลาสที่น้อยที่สุด (random undersampling) ทำซ้ำ **10 ครั้งด้วย seed ต่างกันแล้วเฉลี่ย** เพื่อไม่ให้ผลขึ้นกับการสุ่มครั้งเดียว

ผลลัพธ์ (รายงานทั้งสองแบบตามหลักความโปร่งใส)

โมเดล	กลุ่มตัวอย่าง	n	Accuracy	Baseline	Lift
BUY	เต็ม	500	0.6850	0.5840	+0.1010
BUY	สมดุล	416	0.6642 ± 0.0076	0.5000	+0.1642
FUEL	เต็ม	316	0.4133	0.5316	-0.1183
FUEL	สมดุล	204	0.4423 ± 0.0313	0.3333	+0.1090

ข้อค้นพบ

โมเดล FUEL เปลี่ยนจากต่ำกว่า **baseline 11.8 จุด** เป็นสูงกว่า **baseline 10.9 จุด** (เปลี่ยนแปลง **22.7 จุด**) และโมเดล BUY เพิ่ม lift จาก +10.1 เป็น +16.4 จุด

ทั้งสองโมเดลทำได้ดีกว่าการทายคลาสใหญ่สุดอย่างมีนัยสำคัญเมื่อประเมินบนกลุ่มตัวอย่าง

ที่คลาสสมดุล — ค่าความผันผวนต่ำมาก (BUY ±0.0076) เนื่องจากเฉลี่ยจากการสุ่ม 10 ครั้ง

ข้อสรุปเดิมที่ว่า "โมเดล FUEL ไม่มีอำนาจการทำนาย" จึงไม่ถูกต้อง
ที่ถูกคือ โมเดลมีอำนาจการทำนายจริงในระดับปานกลาง แต่ถูกกลบด้วยสัดส่วนคลาสที่ไม่สมดุลอันเกิดจากการออกแบบการเก็บตัวอย่าง

 **ข้อจำกัดที่ต้องระบุ:** การตัดสินใจประเมินแบบสมดุลเกิดขึ้น หลัง เห็นผลของกลุ่มเต็มแล้ว

จึงรายงานผลทั้งสองแบบควบคู่กันเสมอ ไม่เลือกรายงานเฉพาะแบบที่ตัวเลขดีกว่า และ **accuracy** ยังไม่ถึงเกณฑ์ **80%** ในทั้งสองแบบ

7.8 การผสม SVM กับ ANN (สองอัลกอริทึมตามหัวข้อ 3.3)

การทดลอง ensemble ก่อนหน้าใช้ทั้ง 5 อัลกอริทึมรวมกัน จึงทดสอบเพิ่มเฉพาะการผสม SVM กับ ANN ซึ่งเป็นสองอัลกอริทึมที่เอกสารโครงการระบุไว้โดยตรง (3 รูปแบบ)

วิธี	BUY accuracy	FUEL accuracy
SVM เดี่ยว	0.6915	0.4453
ANN เดี่ยว	0.6445	0.4133
SVM + ANN soft voting	0.6525	0.4117
SVM + ANN ถ่วงน้ำหนักตามคะแนน CV	0.6555	0.4117
SVM + ANN stacking (LogisticRegression)	0.6565	0.3711

ผล: การผสมทำให้ผลแย่ลงในทุกรูปแบบ เนื่องจาก ANN มีประสิทธิภาพต่ำกว่า SVM อย่างชัดเจน (-4.7 จุดใน BUY) การเฉลี่ยความน่าจะเป็นจึงดึงผลลงมา ซึ่งเป็นพฤติกรรมที่คาดหมายได้ของ ensemble เมื่อสมาชิกมีความแข็งแรงไม่เท่ากัน

เปรียบเทียบ SVM กับ ANN โดยตรง (ตามวัตถุประสงค์หัวข้อ 3.3)

ชุดข้อมูล	โมเดล	SVM	ANN	ผลต่าง
n=715	BUY	0.6740	0.6354	SVM +0.0386
n=715	FUEL	0.4148	0.4059	SVM +0.0089
n=500	BUY	0.6882	0.6541	SVM +0.0341
n=500	FUEL	0.4352	0.4324	SVM +0.0028

(ค่า CV balanced accuracy)

SVM ให้ผลดีกว่า ANN ในทุกกรณีที่ทดสอบ (4/4) ซึ่งสอดคล้องกับลักษณะข้อมูล — ANN ต้องการจำนวนตัวอย่างมากกว่าในการเรียนรู้ ขณะที่ SVM แบบ RBF kernel เหมาะกับข้อมูลขนาดกลางที่มีสัญญาณรบกวนสูงมากกว่า

นี่คือคำตอบของวัตถุประสงค์หลักตามหัวข้อ 3.3 ซึ่งบรรลุแล้ว

8. ข้อเสนอเพื่อขอคำปรึกษาจากอาจารย์ที่ปรึกษา

ตามที่หัวข้อ 3.5.1 ของเอกสารโครงการกำหนดให้ประเมินผลด้วย Confusion Matrix ผ่านตัวชี้วัด

4 ตัว (Accuracy, Precision, Recall, F1-Score) ผู้วิจัยขอเสนอแนวทางการรายงานผลดังนี้

ทางเลือกที่ 1 — รายงานเป็น baseline lift ควบคู่กับ 4 ตัวชี้วัดตามที่กำหนดไว้
รายงาน BUY 68.5% เทียบ baseline 58.4% (ดีกว่า 10.1 จุด) พร้อม ROC-AUC 0.715
พร้อมอธิบายหลักการ **accuracy paradox** (accuracy ไม่ใช่ตัวชี้วัดที่เหมาะสมเมื่อ class ไม่สมดุล เพราะโมเดลที่ทายกลุ่มใหญ่เสมอก็ได้ accuracy สูงโดยไม่มีประโยชน์จริง)

ทางเลือกที่ 2 — เพิ่มการรายงานแบบ Selective Classification

รายงานเป็นคู่ coverage–accuracy ที่ระดับที่กำหนดไว้ล่วงหน้า ซึ่งจะแสดงตัวเลขระดับ 80% ได้อย่างมีนัยสำคัญ และสอดคล้องกับนิยาม "ระบบสนับสนุนการตัดสินใจ"

ทางเลือกที่ 3 — ดำเนินการเพิ่มเติมก่อนสรุป

ทดลอง hierarchical classification, confident learning และ ordinal treatment เพื่อให้สามารถระบุได้เต็มปากว่าตรวจสอบครบทุกแนวทางแล้ว (คาดหวังผล +2 ถึง +5 จุด)

ทางเลือกที่ 4 — หากยืนยันเป้า 80% แบบ full-sample

จำเป็นต้องออกแบบแบบสอบถามใหม่ทั้งฉบับ (multi-item battery ต่อ construct เพื่อรองรับ

PLS-SEM/IRT) และเก็บข้อมูลรอบใหม่ ซึ่งอยู่นอกกรอบเวลาที่เหลือของโครงการ

8.5 ข้อสังเกตเชิงระเบียบวิธี — กับดักการประเมินผลที่ตรวจพบระหว่างการวิจัย

(หัวข้อนี้เสนอให้เขียนลงในบทที่ 4 หรือภาคผนวก เพราะแสดงความรู้ความถี่ของกระบวนการตรวจสอบ)

ระหว่างการทดลอง Confident Learning (Northcutt et al., 2021) ผู้วิจัยพบว่าวิธีการที่ถูกต้อง หากประเมินผลผิดวิธี จะให้ตัวเลขที่สูงเกินจริงอย่างมีนัยสำคัญ

การประเมินที่ผิด

คัดตัวอย่างที่อัลกอริทึมระบุว่าน่าสงสัยว่า label ผิดออกจาก ชุดข้อมูลทั้งหมด แล้ววัด accuracy ใหม่ ได้ผล **0.6850** → **0.8673** (สูงขึ้น 18.2 จุด)

ตัวเลขนี้ดูน่าพอใจ แต่เมื่อตรวจสอบรายละเอียดพบว่า:

	จำนวนตัวอย่าง	จำนวนที่ทำนายผิด
ก่อนคัด	500	≈ 158
หลังคัด	404	≈ 54

คัดออก 96 ตัวอย่าง แต่จำนวนที่ทำนายผิดลดลงถึง ≈ 104 ตัวอย่าง

แสดงว่าตัวอย่างที่ถูกคัดออกเกือบทั้งหมดคือตัวอย่างที่โมเดลทำนายผิด

สาเหตุ: อัลกอริทึมใช้ค่าความน่าจะเป็นจากโมเดลตัวเดียวกันเป็นเกณฑ์ระบุตัวอย่างที่น่าสงสัย

จึงไปชี้ตัวอย่างที่โมเดลทำนายไม่ถูกโดยตรง เมื่อคัดออกจากชุดทดสอบด้วย

จึงเป็นการประเมินแบบวนซ้ำ (circular evaluation) เทียบได้กับการนำข้อสอบข้อที่ทำไม่ได้

ออกก่อนคิดคะแนน

การประเมินที่ถูกต้อง

คัดตัวอย่างที่น่าสงสัยเฉพาะใน ชุดฝึก (train) เท่านั้น แล้ววัดผลบน ชุดทดสอบ (test) ที่ไม่ถูกแตะต้อง

	Accuracy	Lift
ไม่คัด	0.6850	+0.1010
คัด label ที่น่าสงสัยในชุดฝึก	0.6805	+0.0965

ส่วนต่าง -0.0045 , paired t-test $p = 0.4627 \rightarrow$ ไม่มีนัยสำคัญทางสถิติ

หลักการที่ได้

การตัดตัวอย่างออกจากชุดข้อมูลจะถูกตัดก็ต่อเมื่อ เกณฑ์การตัดเป็นอิสระจากผลการทำนายของโมเดล

ประเภทการตัด	ความถูกต้อง	ผลที่ได้
ใช้เกณฑ์อิสระ (attention check, straight-lining)	✓ ถูกต้อง	ไม่เปลี่ยนแปลงผล
ใช้ความผิดพลาดของโมเดลเป็นเกณฑ์	✗ วนซ้ำ	สูงเกินจริง 18 จุด

ผู้วิจัยจึงรายงานผลจากวิธีที่ถูกตัด (0.6805) และเก็บโค้ดทั้งสองเวอร์ชันไว้ที่ `analysis/full_analysis.py` (เวอร์ชันผิด) และ `analysis/cl_correct.py` (เวอร์ชันถูก) เพื่อการตรวจสอบย้อนหลัง

9. สรุป

วัตถุประสงค์หลักตามที่ระบุในหัวข้อ 3.3 ของเอกสารโครงการ คือ **การเปรียบเทียบประสิทธิภาพของอัลกอริทึม SVM กับ ANN** ซึ่งโครงการนี้ดำเนินการสำเร็จแล้ว และทำเกินขอบเขตที่กำหนด โดยเปรียบเทียบถึง 5 อัลกอริทึม พร้อมการผสมโมเดล 2 รูปแบบ

ผลที่พบว่าทุกอัลกอริทึมให้ค่าใกล้เคียงกัน คือคำตอบของการเปรียบเทียบ ไม่ใช่ความล้มเหลว และการที่ไม่สามารถบรรลุ 80% ได้นั้น มีกรอบทฤษฎี (intention-behavior gap) และ benchmark จากงานตีพิมพ์รองรับว่าเป็นคุณสมบัติของปรากฏการณ์ที่ศึกษา ไม่ใช่ข้อบกพร่องของระเบียบวิธีหรือของผู้วิจัย

เอกสารอ้างอิงที่ใช้ประกอบ

- Sheeran, P. (2002). Intention–behavior relations: A conceptual and empirical review.
European Review of Social Psychology — meta-analysis จาก 422 การศึกษา
- Northcutt, C., Jiang, L., & Chuang, I. (2021). Confident Learning: Estimating Uncertainty in Dataset Labels. *Journal of Artificial Intelligence Research*, 70.
- Chow, C. K. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*.
- Geifman, Y., & El-Yaniv, R. (2019). SelectiveNet: A Deep Neural Network with an Integrated Reject Option. *NeurIPS*.
- Richter, N. F., & Tudoran, A. A. (2024). Elevating theoretical insight and predictive accuracy in business research: Combining PLS-SEM and selected machine learning algorithms. *Journal of Business Research*.
- Shmueli, G., et al. (2019). Predictive model assessment in PLS-SEM: guidelines for using PLSpredict. *European Journal of Marketing*.
- Sharma, et al. (2021). Predicting EV adoption intention using PLS-SEM and Artificial Neural Networks. *Computers & Industrial Engineering*.
- Babbar, R., et al. (2016). On flat versus hierarchical classification in large-scale taxonomies.
- Train, K. (2009). *Discrete Choice Methods with Simulation*. Cambridge University Press.
- Elkan, C. (2001). The foundations of cost-sensitive learning. *IJCAI*.

หมายเหตุเรื่องการอ้างอิง: รายการข้างต้นได้จากการค้นผ่านระบบ AI 3 ระบบ
ควรตรวจสอบต้นฉบับจริงทุกรายการก่อนนำไปอ้างอิงในเล่ม โดยเฉพาะปีที่พิมพ์และ
ชื่อวารสาร
เนื่องจากระบบ AI อาจให้ข้อมูลบรรณานุกรมคลาดเคลื่อนได้