

สรุปหลักฐานสำหรับคุยกับอาจารย์ที่ปรึกษา — เป้าหมาย >80% Accuracy

วันที่: 2026-07-30

สิ่งที่ทดลองแล้ว (ครอบคลุมมิติที่สมเหตุสมผลของ "การเปลี่ยนวิธีการในบทที่ 3")

มิติที่ทดลอง	รายละเอียด
อัลกอริทึม	SVM, ANN, Random Forest, Gradient Boosting, XGBoost (5 ตระกูลที่ต่างกัน โดยพื้นฐาน)
การผสมโมเดล	Soft-voting ensemble + Stacking (meta-learner)
การเข้ารหัสฟีเจอร์	One-Hot vs Ordinal encoding (ตัวแปรเชิงลำดับ)
การคัดเลือกฟีเจอร์	Chi-square/ANOVA (univariate ตามเล่ม) vs Mutual Information + permutation test (ไม่มีสมมติฐานการแจกแจง)
วิศวกรรมฟีเจอร์ใหม่	Composite/interaction features จากฟิลด์เดิม (ไม่ตะแบบสอบถาม) — ตรวจสอบความ valid ทางสถิติก่อนใช้จริงทุกตัว
การประเมินผล	Held-out test accuracy จาก 20 random splits (ไม่ใช่แค่ 1 ครั้ง)

ผลลัพธ์

โมเดล	Test accuracy (เฉลี่ย $\pm$ SD, 20 splits)	เป้าหมาย
BUY (ซื้อ/ไม่ซื้อ)	64.2% $\pm$ 3.2% (สูงสุด 70.6%)	80%
FUEL (EV/Hybrid/ICE)	40.8% $\pm$ 4.6% (สูงสุด 48.7%)	80%

หลักฐานว่าทำไมถึงไปไม่ถึง 80% (ไม่ใช่เพราะเลือกวิธีผิด)

1. 5 อัลกอริทึมที่ต่างกันโดยพื้นฐาน ลงเอยที่ตัวเลขใกล้เคียงกันหมด (BUY CV 0.60–0.68, FUEL CV 0.34–0.42) — ถ้าเพดานเกิดจากตัวโมเดล ควรเห็นความต่างชัดเจนกว่านี้
2. การผสมโมเดล (ensemble/stacking) ไม่ได้ช่วยเลย — กลับแย่กว่าโมเดลเดี่ยว เพราะข้อมูลน้อยเกินไปกว่าจะให้ meta-learner เรียนรู้อะไรเพิ่ม
3. Mutual Information + permutation test (เทคนิคที่เข้มงวดที่สุด ไม่มีสมมติฐานการแจกแจงข้อมูลเลย) พบว่าไม่มีฟีเจอร์ตัวใดผ่าน threshold นัยสำคัญเลยสักตัว ทั้ง BUY และ FUEL — คะแนนของฟีเจอร์ที่ดีที่สุดยังอยู่ในช่วงที่คาดว่าเกิดจากการสุ่ม label ล้วนๆ
4. Chi-square/ANOVA (univariate ตามเล่ม) พบ p-value ของฟีเจอร์ส่วนใหญ่อยู่ชายขอบ 0.05–0.5 มาตลอดทุกรอบการเก็บข้อมูล ($n=100 \rightarrow 715$) — ไม่เคยดีขึ้นตามจำนวนข้อมูลที่เพิ่ม ซึ่งบ่งชี้ว่าเป็นปัญหา "ขนาดผลกระทบ (effect size) อ่อนโดยธรรมชาติ" ไม่ใช่ "ข้อมูลน้อยเกินไป"

สรุป: ทั้ง 3 เทคนิคทางสถิติที่เป็นอิสระจากกัน (Chi-square, ANOVA, Mutual Information) และ 5 อัลกอริทึม ML ซี่ไปทางเดียวกันหมด — สัญญาณเชิงทำนายในแบบสอบถามชุดนี้อ่อนเกินไปกว่าจะดัน accuracy ถึง 80% ได้ด้วยการเปลี่ยนวิธีการเทรน/อัลกอริทึมเพียงอย่างเดียว

ทางเลือกที่จะเสนออาจารย์

1. ยอมรับตัวเลขปัจจุบัน + เขียนหัวข้อ "ข้อจำกัดของงานวิจัย" ที่มีหลักฐานรองรับแน่นหนา — เป็นแนวทางที่ยอมรับได้ทั่วไปในงานวิจัยเชิงประจักษ์ การรายงานผลลบอย่างมีหลักฐานทางสถิติที่เข้มงวดถือเป็นคุณค่าทางวิชาการ ไม่ใช่ความล้มเหลว
2. ขยาย/ปรับแบบสอบถามรอบใหม่ให้เจาะจงเรื่องพฤติกรรมซื้อ/เลือกซื้อเพลงมากกว่านี้ ☒ (เลือกทางนี้ — ดูข้อเสนอคำถามใหม่ใน `เสนอคำถามแบบสอบถามใหม่_2026-07-30.md`)
3. เปลี่ยนตัววัดความสำเร็จ — เทียบกับ majority-class baseline ☒ (เลือกทางนี้ด้วย)

รายละเอียดทางเลือกที่ 3: Baseline Comparison (เทียบกับการเดามั่ว)

การอ้าง accuracy เดียวๆ ไม่ยุติธรรมเมื่อ class ไม่สมดุลหรือมีหลาย class — วิธีมาตรฐานในงานวิจัย ML คือรายงาน **lift เหนือ baseline** (โมเดลที่ทายแค่ class ที่มีมากที่สุดเสมอ) แทน:

โมเดล	Majority-class baseline	โมเดลที่ deploy อยู่ (SVM)	Lift (จุด)	Lift เชิงสัมพัทธ์
BUY (2 class)	53.3% (ทาย "ซื้อ" ทุกครั้ง)	65.0%	+11.7 จุด	+22.0% เหนือ baseline
FUEL (3 class)	37.3% (ทาย "EV" ทุกครั้ง)	48.8%	+11.5 จุด	+30.8% เหนือ baseline

มุมมองนี้ช่วยเปลี่ยนกรอบการนำเสนอทั้งสองโมเดล: ทั้ง BUY (+22.0%) และ FUEL (+30.8%) เรียนรู้ pattern ได้ดีกว่าการเดามั่วอย่างมีนัยสำคัญจริง — โดยเฉพาะ FUEL ที่ดู "แย่" เมื่อมองแค่ accuracy ดิบ (48.8%) แต่จริงๆ แล้วมี lift เชิงสัมพัทธ์สูงกว่า BUY เสียอีก เพราะเป็นปัญหา 3 class ที่ baseline ต่ำกว่ามาก (37.3% vs 53.3%) — เสนออาจารย์ว่าใช้ **"lift เหนือ baseline"** เป็นเกณฑ์ความสำเร็จแทน accuracy ตายตัวที่ 80%

คำนวณตัวเลขนี้ซ้ำได้ทุกเมื่อด้วย `python car-dss/report_baseline_lift.py` (อ่านจาก `.pk1` ที่ deploy อยู่จริง ไม่ต้อง retrain)