

เอกสารถาม-ตอบ: คำถามที่ตรวจสอบแล้วทั้งหมด

โครงการ: ระบบสนับสนุนการตัดสินใจซื้อขายรถยนต์ โดยใช้หลักการทำเหมืองข้อมูล (CarDSS)

วันที่: 2 สิงหาคม 2569

วัตถุประสงค์: รวบรวมคำถามทุกข้อที่เกิดขึ้นระหว่างการพัฒนา พร้อมคำตอบที่มีหลักฐานรองรับ

ใช้ประกอบการหารือกับอาจารย์ที่ปรึกษา และเตรียมตอบคำถามในการสอบป้องกัน

ตัวเลขอ้างอิงหลัก (n=500, วัดจาก 20 random splits, ผ่าน nested cross-validation):

โมเดล	กลุ่มตัวอย่าง	Accuracy	Baseline	Lift
BUY	เต็ม (500)	68.5%	58.4%	+10.1
BUY	สมดุล (416)	66.4%	50.0%	+16.4
FUEL	เต็ม (316)	44.3%	53.2%	-11.8
FUEL	สมดุล (204)	44.2%	33.3%	+10.9

ส่วนที่ 1 — คำถามเกี่ยวกับข้อมูล

Q1. เก็บแบบสอบถาม 500 ชุดเพียงพอหรือไม่ ควรเก็บเพิ่มเป็น 1,000 หรือไม่

ตอบ: เพียงพอแล้ว การเก็บเพิ่มจะไม่ทำให้ผลดีขึ้น

หลักฐานที่ 1 — **Learning curve** (ทดลองจริง):

จำนวนตัวอย่าง	100	200	300	400	500
BUY accuracy	67.7%	69.3%	68.7%	68.2%	68.2%

ค่าคงที่ตั้งแต่ n=100 ความแตกต่างระหว่าง n=100 กับ n=500 ไม่ถึง 1 จุด

หลักฐานที่ 2 — ประวัติการเก็บข้อมูลจริง ตลอดโครงการ:

225 → 505 → 715 → 500 (ชุดใหม่) — ค่า accuracy ไม่เคยขยับเกินค่าความผันผวนของการวัด

สรุป: ข้อจำกัดอยู่ที่ ปริมาณสารสนเทศในตัวแปร (information ceiling)

ไม่ใช่ จำนวนตัวอย่าง — เป็น information-limited dataset ไม่ใช่ sample-limited

(สคริปต์ตรวจสอบ: `analysis/full_analysis.py` หัวข้อ #6)

Q2. เหตุใดจึงไม่นำข้อมูลชุดเดิม (715 ชุด) มารวมกับชุดใหม่ (500 ชุด)

ตอบ: รวมกันไม่ได้ เพราะโครงสร้างตัวแปรต่างกัน

ชุดเดิมมี 44 คอลัมน์ ชุดใหม่มี 59 คอลัมน์ — ผู้ตอบชุดเดิม ไม่เคยเห็นคำถามใหม่ 10 ข้อ

(กรอบ Theory of Planned Behavior และ EV adoption) หากนำมารวม ค่าของ 10 คอลัมน์นั้น

จะว่างทั้งหมดใน 715 แถว ทำให้ใช้ฝึกโมเดลไม่ได้

ข้อมูลชุดเดิมถูกเก็บรักษาไว้ที่ `files/user_from_archive/` มิได้ลบทิ้ง

และถูกนำมาใช้เปรียบเทียบในหัวข้อ Q3

Q3. เหตุใดโมเดล FUEL จึงทำได้ต่ำกว่า baseline ทั้งที่เก็บข้อมูลกลุ่ม ICE เพิ่มแล้ว

ตอบ: การเก็บ ICE เพิ่มเป็นสาเหตุโดยตรงที่ทำให้ค่า lift ตดลง

กลุ่มตัวอย่างรอบนี้เก็บ ICE เพิ่มโดยตั้งใจ (เพื่อแก้ปัญหา ICE มีน้อยเกินไปในรอบก่อน)

จนเป็น $264/500 = 52.8\%$ ทำให้ ICE กลายเป็นคลาสส่วนใหญ่ และ majority-class

baseline
พุ่งจาก 37.28% เป็น **53.16%**

เปรียบเทียบสองชุดข้อมูลด้วยวิธีวัดเดียวกัน (20 splits, ฟิเจอร์เดิมล้วน):

	ชุดเดิม n=715	ชุดใหม่ n=500
FUEL accuracy	40.75%	43.98% ← สูงกว่า
FUEL baseline	37.28%	53.16%
FUEL lift	+3.47	-9.18

accuracy ดิบสูงขึ้น แต่ **lift** ติดลบ เพราะคู่เปรียบเทียบ (**baseline**) ยากขึ้น

เมื่อประเมินบนกลุ่มตัวอย่างที่ปรับให้ทุกคลาสเท่ากัน (สุ่มลด 10 ครั้งแล้วเฉลี่ย):

	accuracy	baseline	lift
FUEL กลุ่มสมดุล (n=204)	44.2%	33.3%	+10.9

สรุป: โมเดล FUEL มีอำนาจการทำนายอยู่จริง แต่ถูกกลบด้วยสัดส่วนคลาสที่เกิดจากการออกแบบการเก็บตัวอย่าง มิใช่การไร้ความสามารถในการทำนาย

(สคริปต์: `analysis/compare_datasets.py`, `analysis/balanced_subsample.py`)

Q4. คุณภาพการตอบแบบสอบถามน่าเชื่อถือหรือไม่

ตอบ: ตรวจสอบด้วย 3 เกณฑ์มาตรฐานแล้ว และผลไม่เปลี่ยนเมื่อคัดผู้ตอบที่น่าสงสัยออก

เกณฑ์	ผลการตรวจ
Straight-lining (ตอบเลขเดียวรวดทั้ง 21 ข้อ)	0 คน
Longstring (ตอบค่าเดิมติดกัน ≥ 14 ข้อ)	0 คน (สูงสุดที่พบ 13)
Attention check (ข้อ reverse-worded)	ไม่สอดคล้อง 278 คน (55.6%)

Sensitivity analysis — ทดสอบซ้ำโดยคัด 278 คนออก:

	ก่อนคัด	หลังคัด (n=222)
BUY	68.5%	67.4%
FUEL	41.3%	44.8%

ผลไม่เปลี่ยนอย่างมีนัยสำคัญ → ยืนยันว่าตัวเลขที่รายงานไม่ได้เกิดจากผู้ตอบไม่ตั้งใจ

 **ข้อจำกัดที่ต้องรายงาน:** พบว่าข้อความกำกับสำหรับผู้วิเคราะห์ ([ข้อนี้เป็น reverse-worded ให้กลับคะแนนตอนวิเคราะห์]) ปรากฏให้ผู้ตอบเห็นในฟอร์มจริง ทำให้ attention check ข้อนั้นใช้ไม่ได้ (ค่าสหสัมพันธ์กับข้ออื่น = +0.049 ทั้งที่ควรเป็นลบ) บ่งชี้ acquiescence bias ทั้งกลุ่มตัวอย่าง — ควรระบุในหัวข้อข้อจำกัดงานวิจัย

ส่วนที่ 2 — คำถามเกี่ยวกับอัลกอริทึมและโมเดล

Q5. เหตุใดจึงเลือกใช้ SVM ไม่ใช่ ANN

ตอบ: ทดสอบทั้งสองทุกครั้ง และ SVM ให้ผลดีกว่าในทุกกรณี (4 จาก 4)

นี่คือคำตอบของวัตถุประสงค์หลักตามหัวข้อ 3.3 ของเอกสารโครงการ (ค่า CV balanced accuracy):

ชุดข้อมูล	โมเดล	SVM	ANN	ผลต่าง
n=715	BUY	0.6740	0.6354	SVM +0.039
n=715	FUEL	0.4148	0.4059	SVM +0.009
n=500	BUY	0.6882	0.6541	SVM +0.034
n=500	FUEL	0.4352	0.4324	SVM +0.003

เหตุผลเชิงทฤษฎี: ANN (Multi-Layer Perceptron) ต้องการจำนวนตัวอย่างมากกว่าในการ

เรียนรู้พารามิเตอร์จำนวนมาก ขณะที่ SVM แบบ RBF kernel เหมาะกับข้อมูลขนาดกลาง ที่มีสัญญาณรบกวนสูงมากกว่า

Q6. นำ SVM และ ANN มาผสมกันจะดีขึ้นหรือไม่

ตอบ: ทดสอบแล้ว 3 รูปแบบ ผลแย่งทุกแบบ

วิธี	BUY	FUEL
SVM เดี่ยว	0.6915	0.4453
ANN เดี่ยว	0.6445	0.4133
SVM + ANN soft voting	0.6525	0.4117
SVM + ANN ถ่วงน้ำหนักตามคะแนน CV	0.6555	0.4117
SVM + ANN stacking (LogisticRegression)	0.6565	0.3711

เหตุผล: ANN มีประสิทธิภาพต่ำกว่า SVM อย่างชัดเจน (−4.7 จุดใน BUY)
การเฉลี่ยค่าความน่าจะเป็นจึงดึงผลลงมา ซึ่งเป็นพฤติกรรมที่คาดหมายได้ของ ensemble เมื่อสมาชิกมีความแข็งแรงไม่เท่ากัน

(สคริปต์: `analysis/svm_ann_ensemble.py`)

Q7. ทดลองอัลกอริทึมอื่นนอกเหนือจากที่ระบุในเล่มหรือไม่

ตอบ: ทดลองครบ 6 อัลกอริทึม และการผสมโมเดล 2 รูปแบบ

อัลกอริทึม	อยู่ในเล่ม	ทดสอบแล้ว
Support Vector Machine (SVM)	✓	✓
Artificial Neural Network (ANN/MLP)	✓	✓
Random Forest	—	✓
HistGradientBoosting	—	✓
XGBoost	—	✓
ExtraTrees	—	✓
Soft-voting Ensemble	—	✓
Stacking (meta-learner)	—	✓

ผลสำคัญ: ทุกอัลกอริทึมให้ค่าต่างกันไม่เกิน 1 จุด

รูปแบบนี้เป็นลักษณะเฉพาะของ **information-limited dataset** — เมื่ออัลกอริทึมที่มีกลไกการเรียนรู้ต่างกันโดยสิ้นเชิงให้ผลใกล้เคียงกันหมด แสดงว่าข้อจำกัดอยู่ที่ข้อมูล ไม่ใช่ที่ความสามารถของอัลกอริทึม

Q8. เหตุใดจึงไม่นำโมเดลที่ดีที่สุดของแต่ละรอบมาใช้รวมกัน (BUY จากรอบหนึ่ง FUEL จากอีกรอบ)

ตอบ: ในทางเทคนิคทำได้ แต่ไม่มีเหตุผลรองรับ และเสี่ยงต่อความน่าเชื่อถือ

โมเดล BUY และ FUEL เป็นไฟล์แยกกันโดยสิ้นเชิง จึงใช้คนละชุดข้อมูลได้ในทางเทคนิค

แต่เมื่อวัดด้วยวิธีเดียวกัน ไม่มีชุดข้อมูลใดชนะเพียงด้านเดียว:

	ชุดเดิม n=715	ชุดใหม่ n=500	ผู้ชนะ
BUY accuracy	0.6416	0.6715	ใหม่
FUEL accuracy	0.4075	0.4398	ใหม่
BUY lift	+0.1087	+0.0875	เดิม
FUEL lift	+0.0347	-0.0918	เดิม

วัดด้วย accuracy → ชุดใหม่ดีกว่าทั้งคู่ / วัดด้วย lift → ชุดเดิมดีกว่าทั้งคู่

การเลือกใช้ชุดข้อมูลต่างกันสำหรับแต่ละโมเดลโดยอิงจากตัวเลขที่ได้ จะเข้าข่าย **researcher degrees of freedom** ซึ่งอธิบายได้ยากในการสอบป้องกัน
จึงเลือกใช้ชุดข้อมูลใหม่เป็นผลหลักทั้งสองโมเดล และรายงานการเปรียบเทียบนี้ไว้อย่างโปร่งใส

Q9. เหตุใดจึงไม่คัดตัวอย่างที่โมเดลทำนายผิดออกก่อนวัดผล

ตอบ: ทดสอบแล้วทั้งสองวิธี — วิธีที่ให้ตัวเลขสูงคือวิธีที่ไม่ถูกต้อง

วิธีที่ไม่ถูกต้อง (คัดออกจากทั้งชุดข้อมูล)

ให้ผล 0.6850 → **0.8673** (สูงขึ้น 18 จุด)

ตรวจสอบรายละเอียด:

	จำนวนตัวอย่าง	จำนวนที่ทำนายผิด
ก่อนคัด	500	≈ 158
หลังคัด	404	≈ 54

คัดออก 96 ตัวอย่าง แต่จำนวนที่ทำนายผิดลดลง ≈ 104 ตัวอย่าง

แสดงว่าตัวอย่างที่ถูกคัดออกเกือบทั้งหมดคือตัวอย่างที่โมเดลทำนายผิด

สาเหตุ: เกณฑ์การคัดคำนวณจากค่าความน่าจะเป็นของโมเดลตัวเดียวกัน จึงชี้ไปที่ตัวอย่างที่โมเดลทำนายไม่ถูกโดยตรง เมื่อคัดออกจากชุดทดสอบด้วย จึงเป็น **circular evaluation** เทียบได้กับการนำข้อสอบข้อที่ทำไม่ได้ออกก่อนคิดคะแนน

วิธีที่ถูกต้อง (คัดเฉพาะชุดฝึก วัดผลบนชุดทดสอบที่ไม่ถูกแต่ต้อง)

	Accuracy
ไม่คัด	0.6850
คัด	0.6805

paired t-test $p = 0.4627 \rightarrow$ ไม่มีนัยสำคัญทางสถิติ

หลักการ

การคัดตัวอย่างจะถูกต้องก็ต่อเมื่อ เกณฑ์การคัดเป็นอิสระจากผลการทำนายของโมเดล

ประเภทการคัด	ความถูกต้อง	ผลที่ได้
เกณฑ์อิสระ (attention check, straight-lining)	✓	ไม่เปลี่ยนแปลงผล
ความผิดพลาดของโมเดลเป็นเกณฑ์	✗	สูงเกินจริง 18 จุด

(สคริปต์: `analysis/full_analysis.py` (วิธีผิด) และ `analysis/cl_correct.py` (วิธีถูก)
เก็บไว้ทั้งสองเวอร์ชันเพื่อการตรวจสอบ)

ส่วนที่ 3 — คำถามเกี่ยวกับเป้าหมาย 80%

Q10. มีทฤษฎีหรืองานวิจัยใดที่ทำให้ accuracy ถึง 80% จากข้อมูลแบบสอบถามหรือไม่

ตอบ: ตรวจสอบวรรณกรรมแล้ว ไม่พบวิธีที่ถูกต้องตามระเบียบวิธีที่จะไปถึง 80%

หลักฐานเชิงทฤษฎี — Intention–Behavior Gap

งาน meta-analysis ที่รวบรวมจาก 422 การศึกษา พบว่าโดยเฉลี่ย เจตนาอธิบายความแปรปรวนของพฤติกรรมจริงได้เพียง 28% (Sheeran, 2002)

การทำนายการตัดสินใจซื้อจากตัวแปรเชิงทัศนคติจึงมีเพดานตามธรรมชาติต่ำกว่า 80% มาก โดยไม่ขึ้นกับอัลกอริทึมที่เลือกใช้

หลักฐานเชิงประจักษ์ — เทียบกับงานตีพิมพ์

งานวิจัย	ลักษณะข้อมูล	Accuracy
EV adoption intention, ตุรกี (2026)	แบบสอบถาม n=304	63.9%
Purchase intention (PLS-SEM + ML)	Survey-based	64.2 / 77.9 / 64.5%
Sharma et al. (2021)	PLS-SEM + ANN	71.3–74.8%
Latent Class Choice Model	3 คลาส ประเภทเครื่องยนต์	52.4–58.1%
โครงการนี้ (BUY)	แบบสอบถาม n=500	68.5%
EV ownership, US NHTS	ข้อมูลระดับประเทศ 232 ล้านคน	82.7%

งานที่ทำ **accuracy** เกิน 80% ล้วนใช้ข้อมูลระดับประเทศขนาดใหญ่มาก หรือ ข้อมูลพฤติกรรมจริง

ส่วนงานที่ใช้แบบสอบถามเชิงทัศนคติขนาดหลักร้อยราย อยู่ในช่วง 52–75% ทั้งหมด

ช่วงมาตรฐานสำหรับงานลักษณะนี้: **2 คลาส 62–72% / 3 คลาส 45–60%**

Q11. มีแนวทางเชิงเทคนิคใดที่ยังไม่ได้ลองหรือไม่

ตอบ: ตรวจสอบครบ 8 กลุ่มแนวทาง ดำเนินการจริงทุกข้อที่ทำได้

แนวทาง	สถานะ	ผล
Selective classification / Conformal prediction	✅ ทดลองแล้ว	BUY 77.7% ที่ coverage 50% (ไม่ถึง 80%)
Hierarchical / Nested classification	✅ ทดลองแล้ว	+1.25 จุด
Confident Learning (label noise)	✅ ทดลองแล้ว	p=0.46 ไม่มีผล
Ordinal treatment (ICE < Hybrid < EV)	✅ ทดลองแล้ว	QWK = 0.133
BorderlineSMOTE / SMOTETomek	✅ ทดลองแล้ว	ไม่เปลี่ยนผล
Cost-sensitive learning	⚠️ ไม่ตรงเป้า	เปลี่ยนสมดุล ไม่เพิ่ม accuracy
PLS-SEM + ML hybrid	❌ ทำไม่ได้	ต้องมีหลาย item ต่อ construct แต่แบบสอบถามเป็น single-item
Item Response Theory / Factor score	❌ ทำไม่ได้	เงื่อนไขเดียวกัน
Latent Class Analysis แยกเทรน	❌ ไม่แนะนำ	n=500 แบ่ง segment เหลือ 150–250 ต่อกลุ่ม

หมายเหตุ: ข้อ 7–8 ทำไม่ได้เพราะแบบสอบถามออกแบบเป็น 1 คำถามต่อ 1 แนวคิด หากต้องการใช้เทคนิคเหล่านี้ ต้องออกแบบแบบสอบถามใหม่ให้มี 3–4 ข้อต่อ construct

Q12. หลักฐานใดยืนยันว่าเป็นพาดานของข้อมูลจริง มิใช่ข้อบกพร่องของผู้วิจัย

ตอบ: มีหลักฐานอิสระ 5 ชิ้นที่สอดคล้องกัน

1. **Learning curve** แบบ ตั้งแต่ $n=100 \rightarrow$ เพิ่มข้อมูลไม่ช่วย
2. **6 อัลกอริทึมให้ผลต่างกันไม่เกิน 1 จุด** $\rightarrow$ ไม่ใช่ข้อจำกัดของอัลกอริทึม

- 3. **Cluster analysis: Cramér's V = 0.04–0.13** → เมื่อแบ่งกลุ่มผู้ตอบตามโครงสร้างธรรมชาติของข้อมูล กลุ่มที่ได้ไม่สัมพันธ์กับประเภทเชื้อเพลิงที่เลือกเลย
- 4. **Selective classification ของ FUEL ไม่ขยับทุกระดับ coverage** → ค่าความมั่นใจของโมเดลไม่มีสารสนเทศ (โมเดลไม่ทราบว่าตนกำลังจะทำนายผิดเมื่อใด)
- 5. **Nested cross-validation** ต่างจากค่าที่รายงานไม่ถึง 1 จุด → ไม่มี selection bias

ส่วนที่ 4 — ข้อค้นพบเชิงระเบียบวิธีที่ควรรายงาน

F1. ตัวแปรตามของโมเดล BUY ไม่ตรงกับ construct ที่ตั้งใจวัด

คำถามที่ใช้เป็นตัวแปรตามคือ:

"ท่านมีแนวโน้มจะซื้อรถยนต์ตามประเภทเชื้อเพลิงที่ท่านสนใจหรือไม่"

วลี "ตามประเภทเชื้อเพลิงที่ท่านสนใจ" ทำให้คำถามนี้วัด **ความเป็นไปได้ที่จะซื้อรถตามชนิดเชื้อเพลิงที่ชอบ** (conditional purchase) มิใช่ **ความตั้งใจซื้อ** (purchase intention) ตามกรอบ Theory of Planned Behavior

อธิบายผลที่ดูขัดแย้งได้ทั้งหมด:

ผลที่ดูขัดแย้ง	คำอธิบาย
ตัวแปร "เจตนาซื้อภายใน 6 เดือน" ไม่สัมพันธ์กับตัวแปรตาม (p=0.207)	วัดคนละ construct — ผู้ตอบตั้งใจซื้อจริง แต่จะไม่ซื้อชนิดที่ตนชอบ
"การมีจุดชาร์จ" สัมพันธ์กับ BUY (p=0.0001) แต่ไม่สัมพันธ์กับ FUEL (p=0.950)	สอดคล้องกัน — จุดชาร์จกำหนดความเป็นไปได้ที่จะซื้อตามที่ชอบ ส่วน "ชอบชนิดใด" เป็นคนละประเด็น

ข้อเสนอ: ปรับถ้อยคำของคำถามวิจัยให้ตรงกับสิ่งที่วัดจริง และอภิปรายในบทที่ 5

⚠ **ไม่เปลี่ยนตัวแปรตามเป็นคำถามเจตนาซื้อ** เพราะจะเข้าข่าย outcome switching (เปลี่ยนหลังเห็นผล) และเกิด construct leakage (ตัวแปรอิสระตาม TPB ออกแบบมาอธิบายเจตนาโดยตรงอยู่แล้ว)

F2. ข้อบกพร่องของแบบสอบถามที่ตรวจพบ

ข้อความกำกับสำหรับผู้วิเคราะห์ปรากฏให้ผู้ตอบเห็นในคำถามวัดทัศนคติด้านสิ่งแวดล้อมข้อที่ 5 ทำให้ใช้เป็น attention check ไม่ได้ — ควรระบุในหัวข้อข้อจำกัดงานวิจัย

F3. ข้อสังเกตเรื่องกับดักการประเมินผล

พบว่าเทคนิคที่ถูกต้อง (Confident Learning) หากประเมินผลผิดวิธี จะให้ตัวเลขสูงเกินจริงถึง 18 จุด — บันทึกไว้เป็นข้อสังเกตเชิงระเบียบวิธี (รายละเอียดใน Q9)

ส่วนที่ 5 — ประเด็นที่ขอคำปรึกษาจากอาจารย์ที่ปรึกษา

เอกสารโครงการหัวข้อ 3.5.1 กำหนดตัวชี้วัดไว้ 4 ตัว (Accuracy, Precision, Recall, F1-Score)

ผ่าน Confusion Matrix แต่ยังไม่ได้กำหนดเกณฑ์การยอมรับผลเป็นตัวเลข

ผู้วิจัยจึงขอคำปรึกษาว่าควรกำหนดเกณฑ์อย่างไรให้สอดคล้องกับลักษณะข้อมูลที่เก็บได้จริง

ทางเลือกที่เสนอ:

1. รายงานเป็น **baseline lift** ควบคู่กับตัวชี้วัด 4 ตัวตามที่กำหนด พร้อมอธิบายหลัก *accuracy paradox* (accuracy ไม่เหมาะสมเป็นเกณฑ์เดียวเมื่อคลาสไม่สมดุล)
2. เพิ่มการรายงานแบบ **selective classification** — รายงานคู่ coverage/accuracy ที่ระดับซึ่งกำหนดไว้ล่วงหน้า สอดคล้องกับนิยาม "ระบบสนับสนุนการตัดสินใจ"

ที่ไม่จำเป็นต้องพึงธงทุกกรณี

3. รายงานผลของ **FUEL** พร้อมบริบทเรื่องสัดส่วนคลาส — สัญญาณการทำนายมีอยู่จริง (lift + 10.9 บนกลุ่มสมดุล) แต่ถูกกลบด้วยสัดส่วน ICE ที่สูงในกลุ่มตัวอย่างรอบนี้
4. หากยืนยันเกณฑ์ **80%** แบบเต็มกลุ่มตัวอย่าง — จำเป็นต้องออกแบบแบบสอบถามใหม่
ทั้งฉบับ (multi-item battery ต่อ construct เพื่อรองรับ PLS-SEM/IRT) และเก็บข้อมูลรอบใหม่
ซึ่งอยู่นอกกรอบเวลาที่เหลือของโครงการ

ภาคผนวก — การตรวจสอบย้อนหลัง

สคริปต์ที่ผลิตตัวเลขทุกตัวในเอกสารนี้เก็บไว้ที่ `analysis/` พร้อม `README.md` ที่ระบุว่าสคริปต์ใดผลิตตัวเลขในหัวข้อใด ทุกสคริปต์รันซ้ำได้และไม่แก้ไขโมเดลที่ใช้งานจริง

สคริปต์	ใช้ตอบคำถาม
<code>full_analysis.py</code>	Q1 (learning curve), Q11, Q12
<code>compare_datasets.py</code>	Q2, Q3, Q8
<code>balanced_subsample.py</code>	Q3
<code>quality_screen.py</code> / <code>sensitivity.py</code>	Q4
<code>svm_ann_ensemble.py</code>	Q5, Q6
<code>c1_correct.py</code>	Q9
<code>ablation.py</code> / <code>alt_framing.py</code>	Q11

หมายเหตุเรื่องบรรณานุกรม: รายการอ้างอิงในเอกสารนี้ได้จากการสืบค้นผ่านระบบ AI ควรตรวจสอบต้นฉบับจริงทุกรายการ (ปีที่พิมพ์ ชื่อวารสาร) ก่อนนำไปอ้างอิงในเล่ม